

Modul A: Inteligentni sistemi za podporo odločanju

Domača naloga 5

Dominik Bernik¹

¹ Univerza v Ljubljani, Fakulteta za Elektrotehniko
E-pošta: db0975@student.uni-lj.si

1 Uvod

Pri tej laboratorijski vaji smo se osredotočili na implementacijo prediktivnega vodenja s pomočjo metode MPC (ang. Model Predictive Control).

Za uspešno implementacijo prediktivnega krmilnika MPC smo se oprli na rezultate 4. laboratorijske vaje, v kateri smo izvedli identifikacijo sistema ter zgradili njegov dinamični model. Pridobljeni model smo nato uporabili za izvajanje simulacij napovedovanja prihodnjega odziva sistema, ki mu krmilnik MPC sledi z minimizacijo odstopanja od željene referenčne poti.

2 Metodologija

Glavni namen MPC je, da skozi postopek minimizacije pogreška med referenčno vrednostjo in izhodno vrednostjo modela ter da najde najbolj ustrezne vhodne parametre za pravi sistem. Za iskanje te minimalne vrednosti je zato potrebno narediti sprehod čez vse možne vhodne parametre. Pri tej seminarski nalogi je vhodni parameter omejen na naslednje vrednosti:

$$0 \text{ Nm} < u(k) < 3 \text{ Nm} \quad (1)$$

Glede na vhodni parameter $u(k)$ se naš sistem začne odzivati, in nam vrne vrednost y v stopinjah. Tu je naš predpostavljeni cilj, da se sistem nahaja med

$$\phi \in [20^\circ, 80^\circ] \quad (2)$$

Kljub želenemu delovnemu območju je sistem sposoben delovati od 0° do 100° .

2.1 Lokalni mehki model (ang. Local Fuzzy Model)

Za reševanje te naloge sem iz laboratorijske vaje 4 izbral lokalni mehki model (ang. Local Fuzzy Model), ki nam omogoča simuliranje odziva sistema glede na vhodni parameter. Za delovanje modela smo zato morali iz prejšnje laboratorijske vaje prevzeti θ_{local} in centre $c = [c_x, c_y]$ individualnih modelov.

Tabela 1: Lokalni mehki model: θ_{local} (stopinje)

LFM	$u(k)$	$u(k-1)$	$y(k-1)$	$y(k-2)$	1
1	0.017	0.047	1.457	-0.586	-0.011
2	0.021	0.035	1.584	-0.697	-0.009
3	0.019	0.041	1.520	-0.640	-0.011
4	0.020	0.036	1.581	-0.694	-0.009
5	0.020	0.039	1.547	-0.664	-0.010

Tabela 2: Lokalni mehki model: centri c_x, c_y

LFM	c_x	c_y
1	1.7906	0.8020
2	0.1918	0.1834
3	2.3567	1.2609
4	0.8929	0.3604
5	2.7668	1.7451

S pomočjo zgornjih centrov smo nato lahko izračunali inverzno razdaljo centrov v odvisnosti od vhodnega in izhodnega signala sistema notiranega z $z(k) = [u(k), y(k)]$.

$$\mu_i(z(k)) = \frac{1}{\sqrt{(u(k) - c_{x,i})^2 + (y(k) - c_{y,i})^2 + \epsilon}} \quad (3)$$

Inverzna razdalja je bila nato normalizirana in uporabljena kot utež za posamezen lokalni model.

$$\phi_i(z(k)) = \frac{\mu_i(z(k))}{\sum_{j=1}^R \mu_j(z(k))} \quad (4)$$

Tu smo prav tako morali definirati regresorski vektor X_e , ki ga nato lahko uporabimo za izračun posameznih odzovov modela $\hat{y}_i(k)$:

$$X_e = [u(k), u(k-1), y(k-1), y(k-2), 1] \quad (5)$$

$$\hat{y}_i(k) = \theta_{\text{local},i}^T \cdot X_e \quad (6)$$

Za končni rezultat smo nato morali sešteti utežene odzive posameznih modelov, kar nam da odziv sistema $\hat{y}(k)$:

$$\hat{y}(k) = \sum_{i=1}^R \phi_i(z(k)) \cdot \hat{y}_i(k) \quad (7)$$

S pomočjo zgornjega modela smo nato začeli z implementacijo krmilnega sistema MPC.

2.2 Priprava vhodnega signala in referenčne poti

Podobno kot pri 4. laboratorijski vaji sem za generiranje vzbujevalnega signala uporabil naključne stopničaste signale, omejene z zgornjo in spodnjo mejo:

$$u_{\min} \leq u(k) \leq u_{\max} \quad (8)$$

pri čemer je veljalo $u_{\min} = 0,8$ in $u_{\max} = 2,7$.

Poleg stopničastega signala smo na koncu dodali še sinusni signal, ki nam je omogočil preizkušanje in ocenjevanje dinamičnega odziva sistema na celotnem območju delovanja. Pripravljen vhodni signal $u(k)$ smo najprej poslali v sistem in prodobili izhoni signal. Pridobljeni izhodni odziv procesa smo nato uporabili kot željena referenčno pot $r(k)$ (ang. true reference), ki jo MPC krmilnik zasleduje.

Za evalvacijo uspešnosti vodenja in sledenja referenci smo izračunali metrike RMSE in MSE tako za izhodni signal y kot tudi za krmilnem signalu u .

2.3 MPC (ang. Model Predictive Control)

Glavna ideja MPC krmilnega sistema je, da se na podlagi trenutnega stanja sistema simulira horizon dolžine H za vse mogoče vhodne parametre.

Vrednost horizonta H nam pove, za koliko korakov v prihodnost bomo izvedli simulacijo in nato izhodne vrednosti tega horizonta primerjali z našo referenčno vrednostjo.

Glavni cilj prediktivnega vodenja je določiti optimalni parameter $\mathbf{p}$ tako, da minimiziramo napako med simuliranim potekom izhoda na horizonu in referenčno vrednostjo ob upoštevanju omejitev.

Uporaba horizonta je tu ključna, saj s simulacijo bližnje prihodnosti zajamemo tudi dinamiko sistema. Kot dodatni parameter lahko za horizon definiramo tudi spreminjajoče se parametre oz. parametrizacijo krmilnega signala. To naredimo tako, da določimo, kolikokrat želimo parameter optimizirati (S) in za koliko vzorcev (dolžine segmentov L_s) bodo ti uporabljeni, pri čemer velja:

$$H = \sum_{s=1}^S L_s \quad (9)$$

2.3.1 Napovedovanje na horizonu in parametrizacija vhoda

V vsakem diskretnem koraku k na podlagi trenutnega stanja sistema oziroma preteklih izhodov in vhodov signalov ter izbranega parametričnega vektorja vhoda:

$$\mathbf{p} = [p_1, p_2, \dots, p_S]^T \quad (10)$$

izvedemo simulacijo horizonta dolžine H ($j = 1, \dots, H$) na celotno zaporedje krmilnih vhodov $u(k+j-1)$.

Vhodni signal po segmentih dolžine L_s zapišemo kot:

$$u(k+j-1) = p_s \quad \text{za} \quad \sum_{i < s} L_i < j \leq \sum_{i \leq s} L_i \quad (11)$$

S tako pripravljenim vhodnim zaporedjem in z uporabo mehkega modela izvedemo odprto-zančno simulacijo (ang. free-run simulation) napovedanih izhodov $\hat{y}(k+j)$ za vse korake horizonta $j = 1, \dots, H$.

2.3.2 Optimizacija in določanje parametra u

Optimalni vektor parametrov $\mathbf{p}^*$ določimo z minimizacijo namenske funkcije $J(\mathbf{p})$, ki penalizira odstopanje napovedanega izhoda od referenčne poti $\mathbf{r}$ ter spremembe krmilnega signala oziroma dušenje odstopanj vhoda:

$$J(\mathbf{p}) = \sum_{j=1}^H (r(k+j) - \hat{y}(k+j | \mathbf{p}))^2 + \lambda_{\Delta u} \sum_{s=1}^S (p_s - p_{s-1})^2 \quad (12)$$

pri čemer za $s = 1$ velja $p_0 = u(k-1)$, ki lahko predstavlja zadnji dejansko uporabljeni vhod na procesu. Optimizacija poteka ob upoštevanju nasičenja izvajalnega člena:

$$u_{\min} \leq p_s \leq u_{\max}, \quad \forall s \in \{1, \dots, S\} \quad (13)$$

Ko je optimizacija končana, iz optimalnega zaporedja $\mathbf{p}^*$ uporabimo samo prvi krmilni korak $u(k) = p_1^*$, ki ga apliciramo na realni proces. V naslednjem vzorčnem koraku $k+1$ pomaknemo horizon za en korak naprej in celoten postopek ponovimo.

2.4 Evalvacija vodenja

Za oceno kakovosti vodenja ter natančnosti sledenja referenčni poti na celotnem simulacijskem intervalu dolžine N smo izračunali RMSE (ang. Root Mean Square Error) in srednjo kvadratno napako (MSE) za u in y .

RMSE za izhodni signal y (sledenje referenci) definiramo kot:

$$\text{RMSE}_y = \sqrt{\frac{1}{N} \sum_{k=1}^N (y_{\text{cl}}(k) - r(k))^2} \quad (14)$$

Prav tako lahko evalviramo odstopanje krmilnega signala u glede na referenčni vhodni signal z uporabo RMSE za vhod:

$$\text{RMSE}_u = \sqrt{\frac{1}{N} \sum_{k=1}^N (u_{\text{cl}}(k) - u_{\text{ref}}(k))^2} \quad (15)$$

Dodatno evalvacijo sistema lahko naredimo tudi z MSE:

$$\text{MSE}_y = \frac{1}{N} \sum_{k=1}^N (y_{\text{cl}}(k) - r(k))^2 \quad (16)$$


2.4.1 Vpliv parametrov in modela na delovanje

Na kakovost odziva in uspešnost vodenja z MPC imajo največji vpliv ustrezna izbira dolžine horizonta H , število optimizacijskih segmentov S ter uteževalni faktor spremembe vhoda $\lambda_{\Delta u}$.

Poleg nastavitve krmilnika je ključnega pomena tudi natančnost uporabljenega modela procesa. Model mora čim bolj zanesljivo napovedati prihodnji odziv sistema, saj odstopanja v napovedi povzročijo netočnosti pri optimizaciji ter posledično slabše delovanje in slabšo stabilnost celotnega sistema v zaprti zanki.


3 Rezultati

Po postopku, opisanem v metodologiji, smo najprej ustvarili vhodni signal u , ki ga bo MPC krmilnik poskušal generirati.



Slika 1: Vhodni signal u in referenčna pot r

Ustvarjeni vhodni signal smo nato poslali skozi sistem, s čimer smo ustvarili referenčno pot r , ki ji bo MPC krmilnik poskušal slediti.




Slika 2: Referenčni signal r

Za postopek iskanja najboljših parametrov $\mathbf{p}$ smo uporabili MATLAB funkcijo *fmincon*, ki vsebuje algoritme za optimizirano iskanje parametrov ob prisotnosti omejitev. Algoritem uporablja napredne optimizacijske metode, kar pomeni, da mu ni treba preiskati vseh možnih vrednosti v prostoru iskanja.

Pri izbiri horizonta H smo se odločili za $H = 60$ korakov. Pri frekvenci vzorčenja $T_s = 0,05$ s to pomeni, da simulacija izračuna odziva za naslednje 3 sekunde za vsak korak pri vsakem različnem parametru $\mathbf{p}$. Prav tako smo se odločili za $S = 3$ optimizacijskih parametrov, pri čemer posamezen segment zajema 20 vzorcev, oziroma 1 s.

Po izvedbi prediktivnega vodenja z MPC smo prejeli rezultate, prikazane na sliki 3.



Slika 3: Rezultat vodenja s krmilnikom MPC

Pri analizi rezultatov smo ugotovili, da na določenih območjih model začne nekoliko odstopati od realne dinamike, kar povzroči manjša odstopanja pri sledenju.

Za evalvacijo smo izračunali vrednosti RMSE in MSE za signal u ter izhod y po enačbah 14, 15 in 16. Izhodni signal od referenčne poti odstopa za $RMSE_y = 9,0099$ stopinj, medtem ko krmilni signal odstopa za $RMSE_u = 0,2567$. Vrednost srednje kvadratne napake izhodnega signala pa znaša $MSE_y = 81,18$ (stopinj)².

4 Zaključek

Pri implementaciji metode MPC je ključno, da se zavedamo kakovosti uporabljenega modela in njegovih omejitev. Ker se metoda zanaša na interno simulacijo prihodnosti, se mora model čim bolj natančno ujemati z realnim sistemom, saj odstopanja modela povzročijo napako izbiro optimizacijskih parametrov $\mathbf{p}$.

Poleg natančnosti modela je za uspešno delovanje krmilnika MPC izjemno pomembna tudi pravilna izbira nastavitvenih parametrov, kot so dolžina horizonta H , število sprememb parametra tekom simulacij S ter dolžina posameznih časovnih oken L_s .